MySQL 问答
Rag 问答
离线知识库
bge-m3模型
高频问答对
用户个人信息
用户会话（对话）
存放数据
高频问答对原始问题
高频问答对的原始问题分词
已经回答的问答对
存放数据
统计高频问答对
Mysql
初始化加载问题
Redis
根据问题查询mysql中答案
是
用户 query
是
是否有缓存问题?
否
BM25检索
score>0.85?
否
意图识别 (Bert分类/ LLM+prompt)
通用问题?
否
是
策略选择器
执行query
稀疏向量
稠密向量
milvus向量库
混合检索/双路召回
召回粗排文档 ranker
获取父文档去重
bge-reranker-large 模型重排序
topK上下文
完整提示词
用户 query
LLM (商用API/本地化部署)
生成假设答案 (LLM + prompt)
子查询分解 (LLM+prompt)
问题简化模型 (LLM+prompt)
获取假设问题
把一个问题拆成多个问题
把问题简化
直接检索
假设问题检索
子问题查询
回溯问题检索
AI学科的学费是多少?
人工智能在教育领域的应用有哪些?
AI和Java的课程大纲?
我有一个包含100亿条的数据集想把它存在milvus中查询可以吗?
向量化 (bge-m3混合编码)
langchain框架处理
PDF PPT
DOC DOCX
TXT MD
code image
文档分父块
文档分子块
子块元数据处理 (父块放入元数据)
目的：检查当前的问题是否需求查询知识库
RAG系统的评估
评估指标
检索
上下文相关性
上下文召回率
生成
答案相关性
忠实度
评估工具
ragas
文档解析
基本步骤
1. 使用python的扩展包读取对应的文件
2. 定位到文本、图片、表格等信息
3. 文本直接提取、图片使用OCR工具、表格使用for循环
难点
PDF、doc文档中嵌入的图片、表格、公式、图表等元素的识别
表格跨页问题处理
知识库的评估
使用的工具
中文递归文本分割器
PaddleOCR-VL
PaddleOCR-VL-1.5
Paddle-OCR
DeepSeek-OCR
Chandra OCR可将图像和PDF转html/markdown
使用多模态工具解析步骤
1. 内容转为图片或者PDF文件
2. 直接使用多模态模型直接转为markdown
要求输出图片（知识库的图片）
1. 把markdown的图片存储到对象数据库（七牛云）
2. 使用对数据库，上传文件以后返回url链接
3. 存储向量数据库中