软标签蒸馏的两个超参数讲解

1、两个关键参数

软标签蒸馏（Knowledge Distillation，知识蒸馏）中的两个关键参数：

- α（权重系数）
- T（温度）

2、T（温度）——控制“软标签”的软硬程度

温度 T 用于**调节 teacher 模型输出 softmax 的平滑程度**，让学生模型学习 teacher 的“潜在知识”。

普通 softmax 是：

$$P_i = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

加入温度后的 softmax：

$$P_i^{(T)} = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$$

- 如果 T = 1：就是普通 softmax；
- 如果 T > 1：输出变得更平滑，**弱类别概率也变大**，学生能学到更多“细节”；2->1，8-> 4
- 如果 T 趋近于 0：softmax 趋近 one-hot，更像硬标签。
- 如果 T 趋近于无穷大：softmax 趋近于均匀的分布。

> 把 teacher 模型的输出看作“专家的信心”。
>
> 温度越高，专家越“谦虚”，告诉学生：“其实 B 类也有点可能”；
>
> 温度越低，专家越“武断”：“就是 A，别问！”

一般 T选2到5之间，太高或太低都可能让学生难以学习。设置到2

3、α（权重系数）——平衡自主学习和跟老师学习的重要性

作用：

α 控制 **总损失中“蒸馏损失（软标签）”与“普通交叉熵（硬标签）”的权重比例。**

总损失函数一般是这样的：

$$\mathcal{L} = (1 - \alpha) \cdot \mathrm{CE}(y_{\text{hard}}, p_s) + \alpha \cdot T^2 \cdot \mathrm{KL}(p_t^{(T)} || p_s^{(T)})$$

- CE：交叉熵损失，硬标签
- KL：KL散度损失，蒸馏用的软标签
- p_t：teacher 模型的软输出
- p_s：student 模型的软输出

α 起什么作用？

- **α** 趋近 1：更重视 teacher 的软标签（偏向模仿老师）
- **α** 趋近 0：更重视 ground truth 的硬标签（偏向传统训练）

一般α设置在0.5到0.9之间。0.7